


Fundamentos de Machine Learning

De la Teoría a la Práctica: Una Guía Conceptual



El Despertar de la Máquina: ¿Qué es el Machine Learning?

Programación Tradicional

Reglas explícitas codificadas por humanos.



Machine Learning

Aprender de los datos sin ser programado explícitamente.



Recomendaciones personalizadas basadas en el historial.




Clasificación automática de correos no deseados (Spam).



Toma de decisiones en vehículos autónomos.

Es un subconjunto de la Inteligencia Artificial que incorpora inteligencia a las máquinas al permitirles aprender automáticamente de ejemplos.

La Anatomía del Aprendizaje



El Mapa del Universo ML

Machine Learning

Aprendizaje Supervisado



Aprende de datos con etiquetas conocidas. Predice resultados.

Aprendizaje No Supervisado



Explora datos sin etiquetas. Encuentra relaciones y agrupa similitudes.


Aprendizaje por Refuerzo



Aprende interactuando con un entorno. Maximiza recompensas mediante ensayo y error.

1. Aprendizaje Supervisado: Aprender con un Profesor


El objetivo fundamental es enseñar al modelo a mapear una entrada hacia una salida conocida utilizando datos etiquetados (ejemplos históricos).



**Guía de Estudio
(Input + Output)**



Regresión



Salida Continua

Ejemplo: Predecir el precio exacto de una casa.




Clasificación



Salida Categórica

Ejemplo: Predecir si un correo es Spam o No Spam.

Regresión Lineal: Prediciendo el Futuro Numérico



Clasificación: Tomando Decisiones Categóricas

Escenario: Predecir si un estudiante aprobará o reprobará basado en sus horas de estudio.




Interludio Práctico: El Laboratorio del Científico de Datos

Anaconda (La Caja de Herramientas)



Distribución de código abierto para Python y R. Gestiona paquetes de datos y crea entornos de trabajo aislados para evitar conflictos.

Jupyter Notebook (El Lienzo Interactivo)



Un Entorno de Desarrollo Integrado (IDE) que combina código en vivo, ecuaciones, visualizaciones y texto narrativo. Ideal para la exploración de datos.

El Código en Acción: Clasificando Flores Iris

Paso 1: Cargar Datos


```
pd.read_csv('iris.csv')
```

	longitud_sépalo	ancho_sépalo	longitud_pétalo	ancho_pétalo
1	4.8	3.2	4.2	1.6
2	4.5	3.3	4.2	2.2
3	3.8	2.3	1.4	2.3

Paso 1: Cargar Datos

Paso 2: Separar X e Y

```
X = iris.drop,  
Y = iris['species']
```



Paso 2: Separar X e Y

Paso 3: Entrenar

```
model.fit(X_train, Y_train)
```



Paso 3: Entrenar

Paso 4: Predecir

```
model.predict(new_data)
```



Paso 4: Predecir


Refinando el Modelo: Estandarización y Validación

Estandarización (Manzanas con Manzanas)




Sin StandardScaler, características con números grandes dominan el modelo. La estandarización ajusta todo a una media de 0 y desviación estándar de 1.

Train/Test Split (Evitando el Overfitting)



Separar datos de validación asegura que el modelo generalice y no simplemente memorice. Medimos el éxito usando el Accuracy Score en datos no vistos.

2. Aprendizaje No Supervisado: Encontrando Patrones Ocultos



Clustering: Agrupar elementos donde la similitud interna es alta y la similitud externa es baja.

Clustering y Similitud en el Mundo Real

El Motor Matemático




La métrica de Similitud mide qué tan cerca están dos puntos. Valores más cercanos a 1 indican alta similitud.

Casos de Uso del Mundo Real



Segmentación de Mercado

Agrupar clientes por comportamiento de compra para campañas dirigidas.



Detección de Anomalías

Identificar transacciones inusualmente altas o recurrentes como posible fraude.



Sistemas de Recomendación


Agrupar usuarios basados en historias de consumo para sugerir nuevo contenido.

3. Aprendizaje por Refuerzo: Acción y Recompensa



No hay datos etiquetados. El algoritmo aprende interactuando dinámicamente con su entorno y optimizando sus decisiones a través del ensayo y error.

La Arquitectura de una Decisión



El Universo ML: Resumen

Supervisado	No Supervisado	Por Refuerzo
Mecánica: Usa datos etiquetados (profesor).	Mecánica: Usa datos sin etiquetas.	Mecánica: Interacción basada en recompensas y penalizaciones.
Objetivo: Predecir resultados (Regresión/Clasificación).	Objetivo: Encontrar patrones ocultos y agrupaciones (Clustering).	Objetivo: Aprender la política óptima para tomar decisiones.
Ejemplo Práctico: Predecir precios de casas, correos Spam.	Ejemplo Práctico: Segmentar clientes, detección de fraudes.	Ejemplo Práctico: Vehículos autónomos, robótica industrial.

El Machine Learning no es magia; son matemáticas, datos e iteración transformando la manera en que resolvemos problemas complejos.